



DATA SCIENCE FOR SOCIAL GOOD  
PORTUGAL

Data Science for Social Good

# Curating a COVID-19 data repository: tales and technicalities

DSPT Meetup #77  
The Internet, 7th May 2020



# The formula for Data Science for Social Good



## Beneficiaries

Charities  
NGOs  
Public  
Administration

+



## Volunteers

Data Scientists  
Data Enthusiasts  
Developers  
Designers  
Domain experts

=



## Projects

1-3 months; **Deliverable**  
(small, simple yet able to  
bring value - report,  
interactive visualization,  
predictive model, etc)



## Current status



Past



Associação Zoófila Portuguesa



Currently



Soon



# A COVID-19 data repository: motivation

Since the start of the pandemic, the Portuguese Health Authorities [Direção Geral da Saúde] has been providing **daily status reports** [1] in a PDF file:

- **Closed** format (not easy to extract knowledge from)
- Unstructured
- No **metadata** or data **dictionaries**
- Highly variable

In parallel, the data community was pumping out lots of analyses. By mid-March, still a **low signal-to-noise ratio** and **everyone was individually scraping the same data**.

[1] <https://covid19.min-saude.pt/relatorio-de-situacao/>



# Motivation: why open and reliable data, anyway?

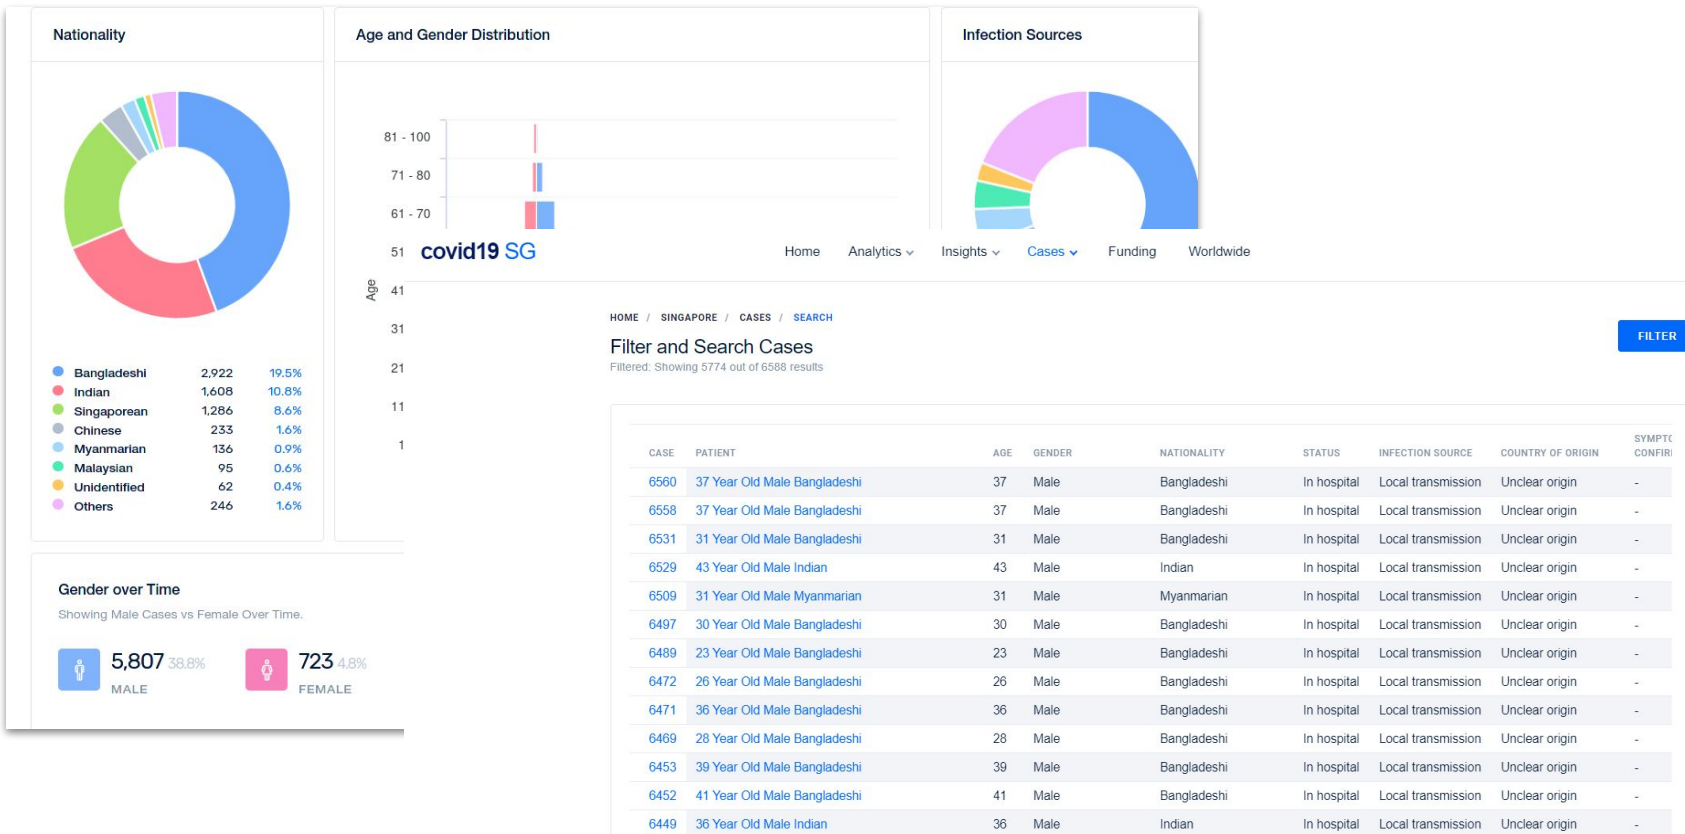
- Transparency and accountability
- Common **official** knowledge base
- Potential for **civic/industrial/academic** involvement

Two **prime** examples of what open and reliable pandemic data enables:

- COVID-19 Singapore Dashboard | UCA [1]
- GitHub Repository of the Italian Civil Protection [2]



# Example: The Singapore dashboard.





# Example: The Singapore dashboard.

covid19 SG

Home

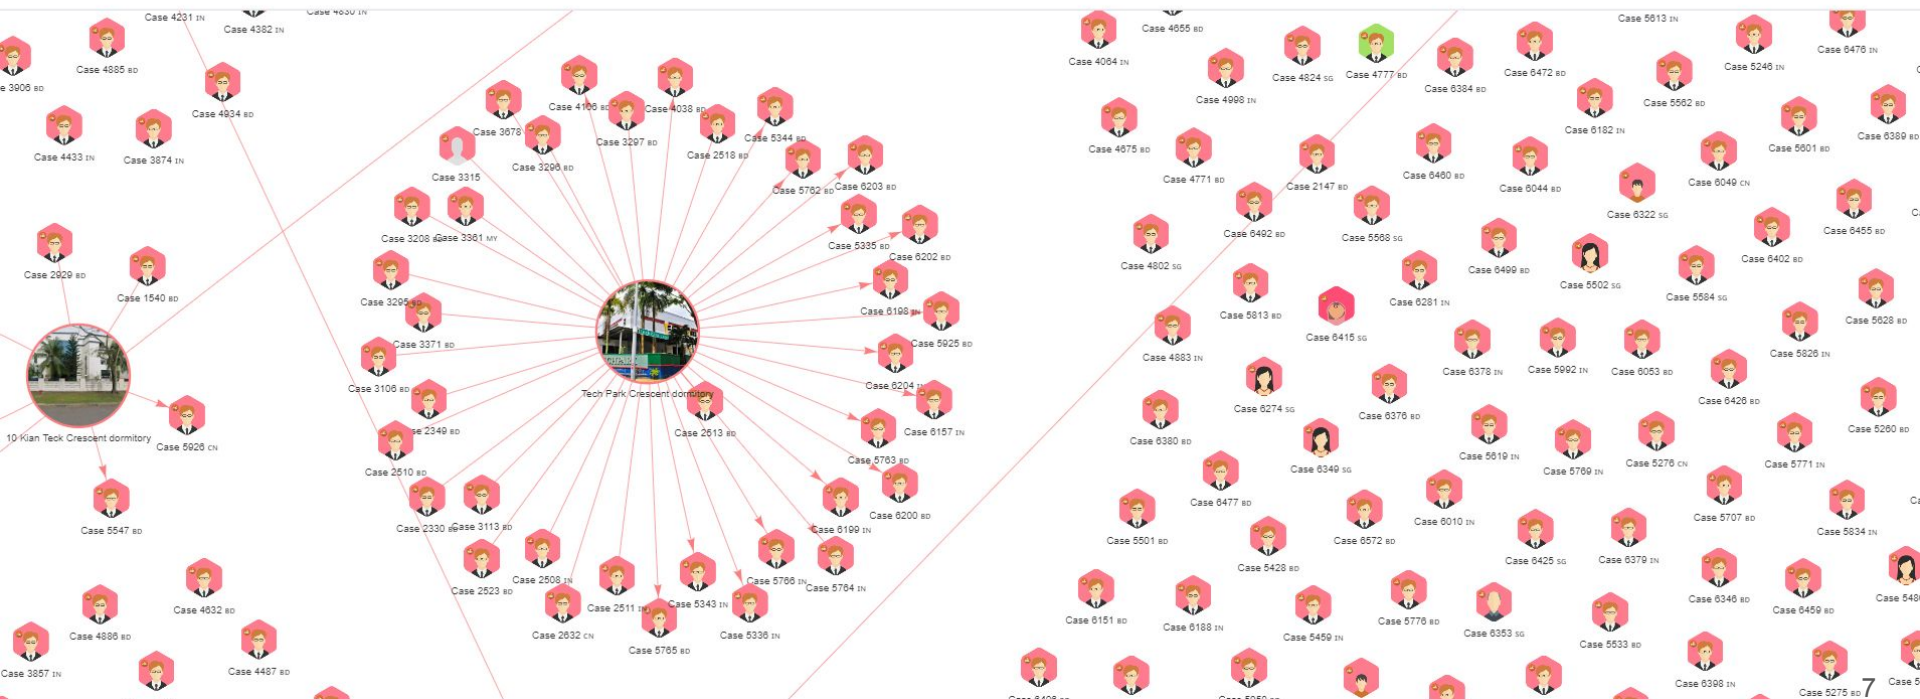
Analytics ▾

Insights ▾

Cases ▾

Funding

Worldwide





# Example: Italian Civil Protection data repository

README.md



PROTEZIONE CIVILE

Presidenza del Consiglio dei Ministri  
Dipartimento della Protezione Civile

[Italiano](#) - [English](#)

## Dati COVID-19 Italia

License [Creative Commons Attribution 4.0 International](#) last commit [today](#)

[Sito del Dipartimento della Protezione Civile - Emergenza Coronavirus: la](#)

Il 31 gennaio 2020, il Consiglio dei Ministri dichiara lo stato di emergenza sanitario connesso all'infezione da Coronavirus.

Al Capo del Dipartimento della Protezione Civile, Anselmo D'Amico, è affidato

## Struttura del repository

```
COVID-19/  
├── aree/  
│   ├── geojson  
│   │   ├── dpc-covid-19-ita-aree-comuni.geojson  
│   │   └── dpc-covid19-ita-aree.geojson  
│   └── shp  
│       ├── dpc-covid19-ita-aree-comuni.dbf  
│       ├── dpc-covid19-ita-aree-comuni.prj  
│       ├── dpc-covid19-ita-aree-comuni.shp  
│       ├── dpc-covid19-ita-aree-comuni.shx  
│       ├── dpc-covid19-ita-aree.dbf  
│       ├── dpc-covid19-ita-aree.prj  
│       └── dpc-covid19-ita-aree.shp
```

## Formato dei dati

- [Dati andamento COVID-19 Italia](#)
- [Dati contratti DPC COVID-19 di fornitura](#)
- [Dati aree misure restrittive COVID19](#)





# Example: *Italian Civil Protection* data repository

Issues **79**

Pull requests **7**

Contributions to master, excluding merge commits





# Motivation



No signs of a **concerted data strategy** from the Portuguese Health Authorities



Can we take it upon ourselves to offer a **central data location** emulating *The Italian Job*?

# 15/03: Repository launch



Turns out we can! [1]


- Started with a **CSV file with epidemiological data** from 26/02 to 14/03 + **archive of the reports**
- At the time, we were manually inserting data but planning on **introducing OCR (Optical Character Recognition)**.
- Had a **comprehensive data dictionary** (first, to our best knowledge).

[1] <https://github.com/dssg-pt/covid19pt-dgs-data>

# 15/03: Repository launch

## Dicionário dos dados

Uma explicação do conteúdo em `data.csv`.

 ARS: Administração Regional de Saúde

Nome da coluna	Significado	Possíveis valores
<code>data</code>	Data da publicação dos dados.	DD-MM-YYYY
<code>data_dados</code>	Data e hora da recolha dos dados apresentados (quando omitida nos relatórios, assume-se como sendo a data da publicação dos dados). <b>Geralmente, os dados são reportados até às 24h do dia anterior à <code>data</code> (equivalentes às 00h do dia de <code>data</code>, sendo este último o formato utilizado).</b>	DD-MM-YYYY HH:MM
<code>confirmados</code>	Casos confirmados	Inteiro >= 0
<code>confirmados_arsnorte</code>	Casos confirmados na ARS Norte	Inteiro >= 0
<code>confirmados_arscentro</code>	Casos confirmados na ARS Centro	Inteiro >= 0
<code>confirmados_arslvt</code>	Casos confirmados na ARS Lisboa e Vale do Tejo	Inteiro >= 0
<code>confirmados_alentejo</code>	Casos confirmados na ARS Alentejo	Inteiro >= 0
<code>confirmados_arsalgarve</code>	Casos confirmados na ARS Algarve	Inteiro >= 0

## Data Dictionary

	<code>data</code>	<code>data_dados</code>	<code>confirmados</code>	<code>confirmados_arsnorte</code>	<code>confirmados_arscentro</code>	<code>confirmados_arslvt</code>
1						
2	26-02-2020	26-02-2020 00:00	0	0	0	0
3	27-02-2020	27-02-2020 00:00	0	0	0	0
4	28-02-2020	28-02-2020 00:00	0	0	0	0
5	29-02-2020	29-02-2020 00:00	0	0	0	0
6	01-03-2020	01-03-2020 00:00	0	0	0	0
7	02-03-2020	02-03-2020 00:00	2	2	0	0
8	03-03-2020	03-03-2020 16:00	4	2	1	1
9	04-03-2020	04-03-2020 17:00	6	3	1	2
10	05-03-2020	05-03-2020 17:00	9	5	1	3
11	06-03-2020	06-03-2020 17:00	13	8	1	4
12	07-03-2020	07-03-2020 17:00	21	15	1	5

## Data file

# OCR would not be a good idea.

## Situação Epidemiológica

- **Mundo:** (European Centre for Disease Prevention and Control (ECDC))
  - 90 663 casos confirmados;
  - 3043 óbitos;
  - Transmissão comunitária ativa: China (Continental e Hong Kong), Piemonte, Veneto), Japão, Singapura, Coreia do Sul.
- **Portugal:**
  - 4 casos confirmados
  - 0 óbitos
  - 101 notificações de casos suspeitos (desde janeiro de 2020)

### Características dos casos

Dos 4 casos confirmados:

- 4 do sexo masculino
- Grupo Etário:

Grupo Etário	Nº casos
30-39	2
40-49	1
60-69	1

- 2 casos importados, 1 da Itália e 1 de Espanha; 2 cont
- Residência (distrito): 2 Porto; 1 Lisboa; 1 Coimbra
- Sintomas
  - Febre: 2
  - Tosse: 2
  - Dores musculares: 2
  - Dor de cabeça: 1
  - Fraqueza generalizada: 1

## SITUAÇÃO EPIDEMIOLÓGICA EM PORTUGAL

Casos suspeitos - 117  
Casos confirmados - 6

4 casos importados



2 casos com ligação a caso confirmado



AÇORES



Confirmados 3

MADEIRA



Confirmados 1

Confirmados 2

### CARACTERIZAÇÃO DOS CASOS

GRUPO ETÁRIO	NÚMERO DE CASOS	
	MASCULINO	FEMININO
30-39 ANOS	2	-
40-49 ANOS	2	1
60-69 ANOS	1	-

FEBRE	TOSSE	DORES MUSCULARES	CEFALEIAS	FRAQUEZA GENERALIZADA
5	3	3	3	1

## SITUAÇÃO EPIDEMIOLÓGICA EM PORTUGAL

Casos suspeitos 181

Casos confirmados 13

### Casos importados

Espanha (1)  
Itália (4)

### Cadeias de transmissão



### CARACTERIZAÇÃO DOS CASOS CONFIRMADOS

GRUPO ETÁRIO	NÚMERO DE CASOS	
	MASCULINO	FEMININO
30-39 anos	2	-
40-49 anos	5	1
50-59 anos	2	-
60-69 anos	2	-
70-79 anos	-	1

CASOS INTERNADOS 13

TOSSE	FEBRE	DIFICULDADE RESPIRATÓRIA	CEFALEIA	DORES MUSCULARES	FRAQUEZA GENERALIZADA
8	11	2	3	6	4

Açores


Madeira

Regiões de residência

Legenda

● 13 de casos confirmados ● 117 de suspeitos

And so it begins: the cycle of manual updates.



aka maintaining a data pipeline with no data contract whatsoever.



And here is **what happened** during that time.

(well, some of it)



## 16/03: First extra data sources added

Besides the official data, we have been adding additional **clean data sources/extra resources** [1] to study the impact of COVID-19 in related areas. As of May 2020:

- **National Healthcare System** (Portal Transparência SNS24)
- **Events** (Civil Protection, Containment Measures)
- **Demographic** (PORDATA)
- **Information Management** (News + Technical Questions [2])
- **Cartographic** (GeoJSON, Shapefiles) [3]

[1] <https://github.com/dssg-pt/covid19pt-data/tree/master/extra>

[2] Gabriel Mourão, <https://github.com/AnthraxisBR>

[3] João Palmeiro, <https://github.com/joaopalmeiro>





## 18/03: First community contribution

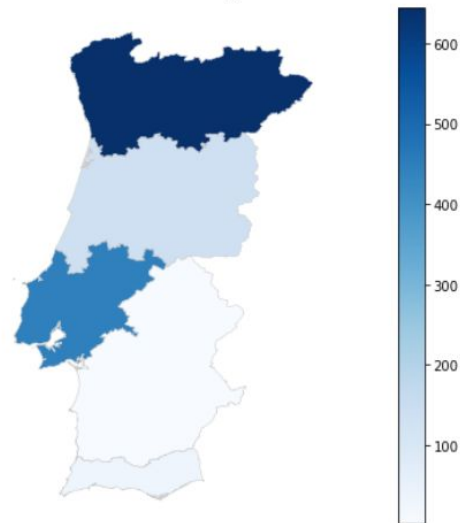
João Palmeiro added cartographic data (GeoJSON, shapefiles) for the Portuguese **NUTS II** regions, useful for visualizing COVID-19 cases per region.

Epidemiological  
data, updated daily

Cartographic data



Casos Confirmados em Portugal Continental: 21-03-2020



Pretty and useful cartographic plots



## 22/03: External API

Carlos Matos (Group IFT) [1], a volunteer, contributed with an **external API built with RapidAPI** [2], for a cleaner access to the epidemiological data in the repository.

It has in the meantime been deprecated, but with the help of the community it took us 8 days from **first commit** -> **available API**.

[1] <https://rapidapi.com/gitgrupoift/api/covid-19-dados-abertos>

[2] <https://grupoift.pt/>

## 22/03: Sponsoring a new category in TAIKAI Challenge

DSPT got us in touch with TAIKAI. The data became the pillar of one category of their online Hackathon: **Coronavirus Analytics by DSSG**. Ongoing!



OVERVIEW

PROJECTS

INNOVATORS

BACKERS

TRANSACTIONS

UPDATES

MATCHMAKING

**FIGHT COVID-19 ONLINE HACKATHON**

BY TAIKAI

## 29/03: Betting on reliability: addition of a test suite

### Why?

- As complexity grew, we noticed that the process of manually introducing data was **fallible**.
- Several institutional users were starting to come up - people were using the data for serious things!

Using `pytest`, a Python unit testing library, we developed a suite of ~**100 data validations** to guarantee maximum reliability:

- The sum of cases per region must equal the total number of cases
- Columns must have certain data types
- Column separator must be a comma

## 29/03: Betting on reliability: addition of a test suite

```
199 ("obitos_80_plus_m", (float, str), _check_column_with_empty),
200 ("obitos_f", (float, str), _check_column_with_empty),
201 ("obitos_m", (float, str), _check_column_with_empty),
202 # Recuperados
203 ("recuperados", (int), lambda x: x >= 0),
204 ("recuperados_arsnorte", (float, str), _check_column_with_empty),
205 ("recuperados_arscentro", (float, str), _check_column_with_empty),
206 ("recuperados_arslvt", (float, str), _check_column_with_empty),
207 ("recuperados_arsalentejo", (float, str), _check_column_with_empty),
208 ("recuperados_arsalgarve", (float, str), _check_column_with_empty),
209 ("recuperados_acores", (float, str), _check_column_with_empty),
210 ("recuperados_madeira", (float, str), _check_column_with_empty),
211 ("recuperados_estrangreiro", (float, str), _check_column_with_empty),
212 ],
213 )
214 def test_dtype(dgs_data, col_name, expected_dtype, extra_check):
215     """
216     Tests whether a certain column has the expected data types (and other column specific rules)
217     """
218
219     df_latest_line = dgs_data.tail(1) # Only run for the latest line
220     for row in df_latest_line.iterrows():
221         val = row[1][col_name]
222
223         # Basic type assertion
```

### ✓ Validate data with pytest

```
90 tests/test_dgs_data.py::test_dtype[recuperados_arslvt-expected_dtype/6-_check_co
91 tests/test_dgs_data.py::test_dtype[recuperados_arsalentejo-expected_dtype77-_che
92 tests/test_dgs_data.py::test_dtype[recuperados_arsalgarve-expected_dtype78-_chec
93 tests/test_dgs_data.py::test_dtype[recuperados_acores-expected_dtype79-_check_co
94 tests/test_dgs_data.py::test_dtype[recuperados_madeira-expected_dtype80-_check_c
95 tests/test_dgs_data.py::test_dtype[recuperados_estrangreiro-expected_dtype81-_che
96 tests/test_dgs_data.py::test_sums[group0-total_col0] PASSED
97 tests/test_dgs_data.py::test_sums[group1-total_col1] PASSED
98 tests/test_dgs_data.py::test_sums[group2-total_col2] PASSED
99 tests/test_dgs_data.py::test_sums[group3-total_col3] PASSED
100 tests/test_dgs_data.py::test_sums[group4-total_col4] PASSED
101 tests/test_dgs_data.py::test_sums[group5-total_col5] PASSED
102 tests/test_dgs_data.py::test_sums[group6-total_col6] XFAIL
103 tests/test_dgs_data.py::test_delimiter_comma PASSED
104 tests/test_dgs_data.py::test_blank_lines PASSED
105 tests/test_dgs_data.py::test_sequentiality_new_cases PASSED
106 tests/test_dgs_data.py::test_sequentiality_dates PASSED
107
108 ===== warnings summary =====
109 /opt/hostedtoolcache/Python/3.7.6/x64/lib/python3.7/site-packages/_pytest/junitxm
110 /opt/hostedtoolcache/Python/3.7.6/x64/lib/python3.7/site-packages/_pytest/juni
111 'xunit2' in pytest 6.0.
112 Add 'junit_family=xunit1' to your pytest.ini file to keep the current format i
113 _issue_warning_captured(deprecated.JUNIT_XML_DEFAULT_FAMILY, config.hook, 2)
114
115 -- Docs: https://docs.pytest.org/en/latest/warnings.html
116 - generated xml file: /home/runner/work/covid19pt-data/covid19pt-data/tests/juni
117 ===== 93 passed, 1 xfailed, 1 warning in 0.85s =====
```

Daily data update: all tests must pass + human approval



## 9/04: Increasing our initiative's impact

- By this time, we were updating daily data **for almost a month** and knew the dataset and its shortcomings pretty well.
- **Errors and inconsistencies** from the Portuguese Health Authorities in the daily reports **were at an all-time high**.
- **Public pressure** concerning release of **open pandemic data** was increasing, yet no external signs towards a proper data strategy.

**We thought we could help.**

## 9/04: Open Letter to the Portuguese Health Authorities

Gathered a few partner entities for added institutional credibility and medical expertise, namely:

- Associação Nacional de Médicos de Saúde Pública
- Centro de Investigação em Tecnologias e Serviços de Saúde
- Faculdade de Medicina da Universidade do Porto
- Tech4Covid19 Movement

Wrote **“Por uma melhor estratégia de dados da Direcção-Geral da Saúde no combate à pandemia COVID-19 em Portugal” [1]**

With constructive and actionable feedback as well as an offer of pro bono help, sent to the Head of the Portuguese Health Authorities and, afterwards, Portuguese media.

[1] <https://tiny.cc/dqs-openletter>

# And off it went.

Pandemia

## Várias associações querem ajudar DGS a melhorar divulgação de dados da Covid-19

Sofia Cristino  
09 Abril 2020 às 14:01



COMENTAR

TÓPICOS

Nacional  
Covid-19  
SARS-CoV-2  
Coronavírus



Várias entidades da  
Saúde (DGS);  
informação s

GETTY IMAGES

Em carta aberta, entidades portuguesas disponibilizam ajuda técnica e estratégica à DGS. Atrasos, retrocessos e más práticas de partilha de dados por parte da autoridade e do ministério da Saúde motivaram-nas a dar esse passo



MARIA JOÃO  
BOURBON

Um conjunto de entidades com experiência na área de ciência dos dados e da saúde enviou uma carta aberta à Direção-Geral da Saúde (DGS), na qual expõem as falhas na disponibilização de dados por parte da autoridade e disponibilizam ajuda técnica e estratégica. O objetivo é alertar a autoridade da saúde para a importância da



A+ / A-

## Associações oferecem apoio à DGS para melhorar estratégia de divulgação de dados

09 abr, 2020 - 14:00 • Joana Gonçalves

Numa carta aberta, as entidades signatárias explicam que o objectivo é alertar para a importância da transparência e da colaboração cívica enraizada nos dados abertos na luta contra a pandemia do Covid-19.

Ordem dos Advogados diz que é ilegal medir temperatura aos trabalhadores

Balanço da DGS. Portugal tem 903 mortes e 23.864 infetados

Veja o número de casos de Covid-19 por concelho. Há duas novas localidades na lista da DGS

Covid-19. Taxa de transmissão volta a subir e Ministra da Saúde apela à contenção social

Coreia do Norte. O que se sabe até agora sobre o estado de saúde Kim Jong-Un

Alemanha confirma que China tentou pressionar Governo para que elogiasse gestão de Pequim





## 9/04: Open Letter - End result

- Currently trying to schedule a meeting with the Portuguese Health Authorities.
- **Overwhelming support** in social networks.
- Kept the **open pandemic data issue in the headlines**, further exerting public pressure.
- Led to a **Motion for Resolution** in the Portuguese Parliament (in analysis).



Data, more and more, a cause, consequence and vehicle for civic intervention.



## 11/04: Automatic PDF scraping... at last!

Teresa Salazar (from Talkdesk) [1] developed a script to automatically extract data from the PDF to our CSV.

- This meant we did not have to manually fill **84 columns** every day.
- Used the `textextract` Python library for **text extraction**, followed by heuristic processing rules (doable as the format had stabilized)
- Library is **sensitive configuration of the host OS**: a Docker environment is recommended for reproducibility

[1] <https://github.com/teresalazar13>



# Automatic Extraction

## Run data extraction

```
1 ▶ Run python .github/workflows/extract_dataset.py
4 [ 'NOVO CORONAVÍRUS', 'COVID-19', 'RELATÓRIO DE SITUAÇÃO', 'SITUAÇÃO', 'EPIDEMIOLÓGICA EM', 'PORTUGAL', 'Total de casos', 'suspeitos (desde 1 de janeiro ', '2020)', 'Total de casos', 'confirmados', '252889', '25282', 'Total de casos não ', 'confirmados', '223916', 'Aguardam resultado', 'laboratorial', 'Casos recuperados', 'Óbitos', 'Contactos em Vigilância', 'pelas Autoridades de ', 'Saúde', '3691', '1689', '1043', '25324', 'Acores', '132', '13', 'Madeira', '86', '0', '15021', '597', '3447', '200', '6047', '210', '218', '1', '331', '13', 'Região de residência', 'ou, caso não exista informação, ', 'região de ocorrência', 'Legenda', 'N.º de casos confirmados', 'N.º de óbitos', 'Dados até dia 02 | MAIO | 2020 | 24:00', 'Atualizado a 03 | MAIO | 2020 | 11:00', '\x8cNOVO CORONAVÍRUS', 'COVID-19', 'RELATÓRIO DE SITUAÇÃO', 'CASOS IMPORTADOS', 'África do Sul (2)', 'Alemanha e Áustria (1)', 'Alemanha e Irlanda (1)', 'Alemanha (10)', 'Andorra (32)', 'Andorra e Espanha (1)', 'Argentina (18)', 'Austrália (15)', 'Áustria (8)', 'Azerbaijão (1)', 'Bélgica (10)', 'Brasil (30)', 'Cabo Verde (4)', 'Canadá (6)', 'Chile (2)', 'China (1)', 'Cuba (2)', 'Dinamarca (1)', 'Egipto (4)', 'Emirados Árabes Unidos (48)', 'Espanha (171)', 'EUA (24)', 'França (137)', 'Guatemala (3)', 'Índia (4)', 'Indonésia (1)', 'Irão (1)', 'Irlanda (3)', 'Israel (3)', 'Itália (29)', 'Jamaica (2)', 'Japão (1)', 'Luxemburgo (2)', 'Maldivas (1)', 'Malta (2)', 'Marrocos (1)', 'México (2)', 'Noruega (1)', 'Países Baixos (19)', 'Paquistão (2)', 'Polónia (1)', 'Qatar (1)', 'Reino Unido (88)', 'República Checa (1)', 'Singapura (1)', 'Suécia (2)', 'Suíça (45)', 'Tailândia (3)', 'Turquia (1)', 'Ucrânia (1)', 'Venezuela (1)', 'Casa não exista informação disponível sobre data de início de sintomas, é ', 'considerada a data de notificação.', 'CARACTERIZAÇÃO DEMOGRÁFICA DOS', 'CASOS CONFIRMADOS', 'GRUPO ETÁRIO', 'MASCULINO', 'FEMININO', 'NÚMERO DE CASOS', '00-09 anos', '10-19 anos', '20-29 anos', '30-39 anos', '40-49 anos', '50-59 anos', '60-69 anos', '70-79 anos', '80+', 'Total', '199', '337', '1245', '1497', '1654', '1670', '1342', '1052', '1286', '212', '418', '1677', '2041', '2569', '2602', '1567', '2678', '10282', '14919', '* 56 são apresentados dados relativos a 25201 casos confirmados por falta de ', 'informação em notificações laboratoriais', 'Dados até dia 02 | MAIO | 2020 | 24:00', 'Atualizado a 03 | MAIO | 2020 | 11:00', '\x8cNOVO CORONAVÍRUS', 'COVID-19', 'RELATÓRIO DE SITUAÇÃO', 'CARACTERIZAÇÃO DEMOGRÁFICA DOS CASOS CONFIRMADOS', 'NÚMERO', 'DE CASOS', 'CONCELHO', 'NÚMERO', 'DE CASOS', 'CONCELHO', 'CONCELHO', 'Abrantes', 'Águeda', 'Albergaria-a-Velha', 'Albufeira', 'Alcácer do Sal', 'Alcanena', 'Alcobaça', 'Alcochete', 'Alenquer', 'Alfândega da Fé', 'Alijó', 'Almada', 'Almeida', 'Almeirim', 'Almodôvar', 'Alpiarça', 'Alvalázere', 'Amadora', 'Amarante', 'Amares', 'Anadia', 'Ansião', 'Arcos de Valdevez', 'Arganil', 'Arouca', 'Arruda dos Vinhos', 'Aveiro', 'Azambuja', 'Baão', 'Barcelos', 'Barreiro', 'Batalha', 'Beja', 'Benavente', 'Bombarral', 'Braga', 'Bragança', 'Cabeceiras de Basto', 'Cadaval', 'Caldas da Rainha', 'Calheta', 'Câmara de Lobos', 'Caminha', 'Cantanhede', '8', '48', '83', '68', '4', '8', '29', '16', '22', '5', '4', '244', '6', '14', '8', '8', '24', '336', '86', '50', '37', '6', '66', '8', '35', '5', '278', '20', '14', '219', '97', '4', '10', '28', '3', '1105', '111', '17', '5', '19', '5', '35', '16', '51', 'Carregal do Sal', 'Cartaxo', 'Cascais', 'Castelo Branco', 'Castelo de Paiva', 'Castro Daire', 'Castro Marim', 'Colorido da Beira', 'Colorido de Basto', 'Chamusca', 'Chaves', 'Cinfães', 'Colimbra', 'Condeixa-a-Nova', 'Coruche', 'Covilhã', 'Cuba', 'Elvas', 'Entroncamento', 'Espinho', 'Esposende', 'Estarreja', 'Évora', 'Fafe', 'Faro', 'Felgueiras', 'Figueira da Foz', 'Figueira de Castelo ', 'Rodrigo', 'Figueiro dos Vinhos', 'Funchal', 'Fundão', 'Góis', '12', '32', '341', '5', '14', '102', '3', '9', '18', '9', '26', '15', '420', '65', '36', '7', '3', '5', '6', '76', '39', '72', '19', '96', '66', '346', '28', '3', '4', '30', '3', '10', 'Gondomar', '1012', 'Gouveia', 'Grândola', 'Guarda', 'Guimarães', 'Horta', 'Ílhavo', 'Lagoa', 'Lagos', 'Lamego', 'Leiria', 'Lisboa', 'Loulé', 'Lousres', '19', '9', '20', '613', '6', '105', '10', '3', '33', '74', '1567', '62', '408', 'Lourinhã', 'Lousã', 'Lousada', 'Macedo de Cavaleiros', 'Madalena', 'Mafra', 'Maia', 'Mangualde', 'Manteigas', 'Marco de Canaveses', 'Marinha Grande', 'Matosinhos', 'DE CASOS', '5', '13', '215', '21', '5', '71', '871', '74', '3', '68', '16', 'Matosinhos', '1149', 'Mealhada', 'Melgaço', 'Mira', 'Miranda do Corvo', 'Miranda do Douro',
```



```
[confirmados_acores_value, obitos_acores_value, confirmados_madeira_value, obitos_madeira_value,
confirmados_arsnorte_value, obitos_arsnorte_value, # recuperados_arsnorte_value,
confirmados_arscentro_value, obitos_arscentro_value, # recuperados_arscentro_value,
] = get_all_numbers_from_list(lines, "Acores", "Total de casos")
```

## 15/04: Fully automated data extraction pipeline

**Almost** fully automated. We used **Github Actions** for running a data extraction pipeline:

- Pull Request **changing the report link** (exact name varies daily)
- **Trigger the workflow:** download the PDF, extract data, update the CSV and then run the test suite to validate it.
- Before merging, the results are **validated** by a member of our Lead Team.

This has been running (somewhat) smoothly **for about two weeks**, with minor changes.





# GitHub Actions?

```
7
8 jobs:
9   build:
10     if: startsWith(github.head_ref, 'dados')
11     runs-on: ubuntu-latest
12     container: python:3
13
14     steps:
15       - uses: actions/checkout@v2
16         with:
17           ref: ${github.head_ref}
18       - name: Install dependencies
19         run: |
20           python -m pip install --upgrade pip
21           python -m pip install -r .github/workflows/requirements.txt
22       - name: Download PDF
23         run: |
24           wget -c -P .github/workflows/ $(cat .github/workflows/report_link.txt)
25       - name: Process PDF
26         run: |
27           python .github/workflows/process_report.py
28       - name: Run data extraction
29         run: |
30           python .github/workflows/extract_dataset.py
31       - name: Add new PDF file to Git repo (it's the only addition to the reports folder)
32         run: |
33           git add -A dgs-reports-archive/
34       - name: Commit all changes
35         uses: stefanzweifel/git-auto-commit-action@v4.1.1
36         with:
37           commit_message: Update data for today
38           branch: ${github.head_ref}
39       - name: Validate data with pytest
40         run: pytest tests/test_dgs_data.py -s -vv --junitxml=tests/junit/test-results.xml
41       - name: Upload pytest test results
42         uses: actions/upload-artifact@master
43         with:
44           name: pytest-results
45           path: tests/junit/test-results.xml
46       # Use always() to always run this step to publish test results when there are test failures
47       if: always()
```



Extract and validate DGS data (from downloaded PDF file) / **build**  
succeeded yesterday in 1m 34s

- ▶ ✓ Set up job
- ▶ ✓ Initialize containers
- ▶ ✓ Run actions/checkout@v2
- ▶ ✓ Install dependencies
- ▶ ✓ Download PDF
- ▶ ✓ Process PDF
- ▶ ✓ Run data extraction
- ▶ ✓ Add new PDF file to Git repo (it's the only addition to the reports folder)
- ▶ ✓ Commit all changes
- ▶ ✓ Validate data with pytest
- ▶ ✓ Upload pytest test results
- ▶ ✓ Post Run actions/checkout@v2
- ▶ ✓ Stop containers
- ▶ ✓ Complete job

**Free service:** human-readable YAML syntax allows definition of **environment** and **arbitrary workflows**; automatic machine provisioning; ideal for **light workloads with specific triggers**.



## 21/04: API for epidemiological data, take 2



Simple `flask` API (documented with `flask-swagger`) for access to epidemiological data, consuming directly from the repository (**always up to date**). It is served using `gunicorn` + `nginx` and deployed using a Docker Container.

- Last update
- Data of a specific day
- Data for a range of days
- Of course, **open-source** [1]. VOST PT is kindly hosting a public instance [2], go make stuff with it!

[1] [https://github.com/dssg-pt/Docker\\_COVID\\_API](https://github.com/dssg-pt/Docker_COVID_API)

[2] <https://covid19-api.vost.pt/>



# Status after 2 months

~300 commits

~60 forks

~200 GitHub 





# Project showcase

dssg-pt/covid19pt-data/ is powering projects in **data visualization**, **data journalism**, **epidemiological surveys**, **predictive epidemiological modelling**, between others. Projects are personal and academic.

P P2 ÍPSILON ÍMPAR FUSAS P3 CINECARTAZ CLUBE P



## Como achatar a curva? O que revelam as experiências dos países


Rui Barros e Dinis Correia - Atualizado a 5 de Abril de 2020 às 13:49

Como achatar a curva dos gráficos de novos infectados na covid-19? É o que vários países afectados pelo

### Evolução de Casos Confirmados por Área de Saúde

No gráfico é possível observar, relativamente aos casos confirmados e em cada dia, a percentagem ocupada por cada área de saúde. É também possível, ao navegar no gráfico, verificar o número de casos confirmados acumulado em cada dia.


■ Norte ■ Centro ■ Lisboa e Vale do Tejo ■ Alentejo ■ Algarve ■ Açores ■ Madeira



## Ainda há Covid-19 amanhã?


(Sim, Pico em caso.)

Infecções Previsto Geral




### Region: Algarve

$R_t$  estimation for Algarve / Portugal (last  $R_t = 0.93$ )



Incidence data (new confirmed cases per day)







# Antero Pires - COVID19 Dashboard

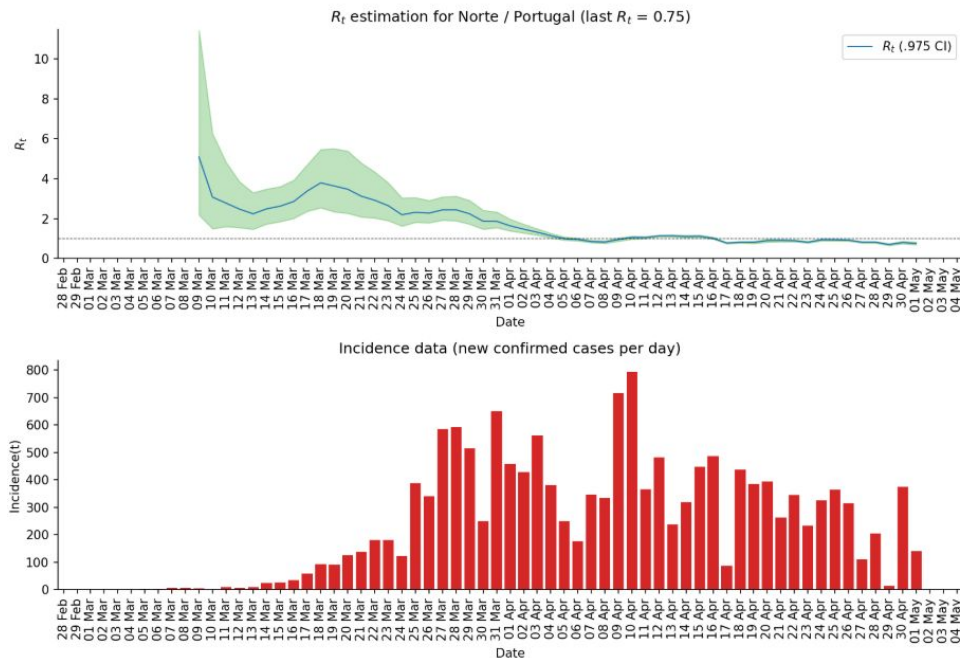


[1] <https://covid19.anteropires.com/>



# Christian Perone - Rt estimation

## Region: Norte

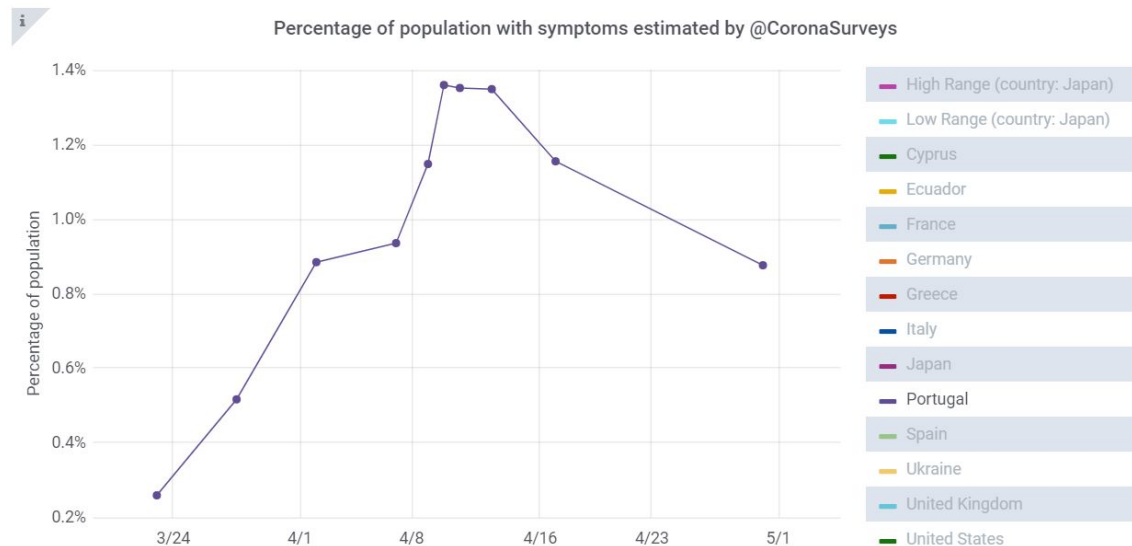




# Coronasurveys - INESC TEC + Univ. Minho

Estimates obtained by CoronaSurveys

(Updated daily)





## Público - Personalized news per municipality

A covid-19 já infectou 25.524 pessoas, das quais 1063 morreram. Mas o novo coronavírus afecta o território nacional de forma diferente. O PÚBLICO recolhe os dados dos 308 concelhos para que possa conhecer a situação em cada um deles.

Altere o título, seleccionando um concelho para obter um artigo personalizado — ou continue a ler para uma visão da evolução da pandemia em Águeda.

CORONAVÍRUS

### Como está a evoluir a pandemia de covid-19 em Águeda?

Rui Barros, Dinis Correia e Hélio Carvalho · Actualizado a 4 de Maio de 2020 às 19:12



(uses part of our data - total # and deaths)

**Águeda** é o 60.º concelho com maior número de infectados com covid-19 em Portugal. De acordo com o último relatório da Direcção-Geral da Saúde (DGS), neste município havia, a 4 de Maio de 2020, 55 casos de covid-19 identificados. Esta região representará menos de 1% dos casos de todo o país.

O número de casos em **Águeda** tem vindo a aumentar nos últimos sete dias 44 55 - uma taxa de crescimento a rondar os 25%.

No território nacional, a maior taxa de crescimento verifica-se na Azambuja 7 21, Almodôvar 3 7 e Manteigas 3 7.

Nesses concelhos registou-se, respectivamente, uma taxa de crescimento numa semana de 200%, 133% e 133%.

Nas últimas 24 horas, o concelho onde o número de infectados mais cresceu em termos percentuais foi Manteigas (133% - de 3 para 7 casos).

## List of projects (partial)

- **Como achatar a curva? O que revelam as experiências dos países [1]**, by Rui Barros and Dinis Correia from jornal Público
- **COVID19 Portugal by Crossroads - Portugal e um olhar sobre o mundo [2]**, by zemanels [3]
- **CoronaSurveys: Monitoring COVID-19 incidence via open polls [4]**, by Universidade do Minho and INESC TEC
- **COVID-19 Time varying reproduction numbers estimation for Portugal [5]**, by Christian Perone [6]
- + a lot more in **Project Showcase issue [7]** + Social Networks!

[1] <https://www.publico.pt/interactivo/coronavirus-como-achatar-curva-que-revelam-experiencias-paises>

[2] <https://covid19.crossroads.pt/> | [3] <https://github.com/zemanels>

[4] <https://coronasurveys.org/>

[5] [https://perone.github.io/covid19analysis/portugal\\_r0.html](https://perone.github.io/covid19analysis/portugal_r0.html) | [6] <https://github.com/perone>

[7] <https://github.com/dssg-pt/covid19pt-data/issues/20>



# So, what's next?

## Just launched

- Number of processed testing samples, updated daily

## Soon...

- Municipality data (and cartographic resources), updated daily PR #85 [1]

## Interesting in helping out?

- Scraper to automatically **detect when a new report is released**.
- Integrate mortality data from **SICO - eVM [3]**.
- Participate in the **TAIKAI** challenge.
- **Your ideas!** Development is all done on GitHub, **transparently**.

[1] <https://github.com/dssg-pt/covid19pt-data/pull/85> | [2] <https://github.com/dssg-pt/covid19pt-data/pull/96>

[3] <https://evm.min-saude.pt/>



## Take-home message

- Society is starting to understand the power of having **transparent and open data**.
- **Automatic validation systems** could prevent mistakes like what have been seen in the last days (duplicated cases).
- To this day, our major challenge will be to guarantee our scripts continue working with the **variability of the daily reports**.
- Our offer for helping the Portuguese Health Authorities is **still standing**, and we're working on operationalizing it.

# Meet us on...



dssg.pt



dssg\_pt



@dssgpt



/DSSGPortugal



DATA SCIENCE FOR SOCIAL GOOD  
PORTUGAL



## DSSG PT !?

- DSSG PT does **not conduct groundbreaking research**.
- DSSG PT is **not a company**.
- DSSG PT is **often looking for new members**, but always for **unpaid positions**.
- DSSG PT, from a purely **technical standpoint**, is a rather **boring endeavour**.

## DSSG PT !?

- DSSG PT always works on **real life problems**.
- DSSG PT delivers not papers, not prototypes, but usable **Data Science products**.
- DSSG PT only works on one type of problems: **those that have a positive impact for society**.



## Aim: to replicate a formula

An open **community** of **data scientists**, **data lovers** and **data enthusiasts** that wants to **tackle problems that really matter**. We believe in the **power of data to transform our society** for the better, for everyone.



Beneficiaries




Volunteers




Projects

# Constant changes in the reported clinical indicators



Report #8



Report #33